

Gossip-Based Service Discovery and Failure Detection

Leonardo Polidori (0357314)

Università Tor Vergata

leonardo.polidori@students.uniroma2.eu

Abstract—Il *service discovery* richiede diffusione rapida ma sostenibile. Il *flooding* garantisce copertura deterministica ma scala male; i protocolli *epidemic* accettano copertura probabilistica con costo per nodo quasi costante e buona resilienza a perdita e churn. Presentiamo un sistema leggero in Go con control plane bimodale: (i) *heartbeats one-hop* (light/full) per liveness e snapshot, (ii) *rumor mongering* multi-hop per lookup ed eventi di guasto con (TTL, B , F) e dedup, (iii) round *anti-entropy* push-pull opzionali per riconciliazione. Il registry è *seed-only* e resta fuori dal data path dei lookup. Usiamo Docker/Compose per avviare topologie ripetibili, esplorare i parametri e iniettare guasti..

Index Terms—gossip, service discovery, failure detection, anti-entropy, rumor spreading, Docker, Go

I. INTRODUZIONE

Nei sistemi distribuiti, la scoperta dei servizi deve bilanciare latenza, costo di rete e robustezza. I registry centralizzati semplificano la coerenza ma introducono un single point of failure; il *flooding* offre copertura elevata a fronte di traffico esplosivo. I protocolli *epidemic* (gossip) spostano l'equilibrio: accettano copertura probabilistica in cambio di un costo per nodo quasi costante e migliore tolleranza a perdita e churn.

Adottiamo un **control plane bimodale**: *heartbeat one-hop* (light/full) per liveness e snapshot locali; *rumor multi-hop* con (TTL, B , F) e dedup per propagare solo gli eventi che devono diffondersi (lookup e transizioni *Suspect/Dead/Leave*); una fase opzionale di *anti-entropy* (push-pull) per riconciliare divergenze. Il registry resta *seed-only* e fuori dal data path dei lookup.

Contributi:

- Architettura *seed-only* con diffusione epidemica di membership e servizi.
- *Lookup* epidemico con TTL/fanout/budget e negative cache con invalidazione a tempo.
- Failure detector a heartbeat con rumor di stato e promozione parametrizzabile (timeout/quorum).
- Metodologia sperimentale in Docker/Compose.

II. FONDAMENTI: GOSSIP, RUMOR, ANTI-ENTROPY, FAILURE DETECTION

A. Epidemic Gossiping (push, pull, push-pull)

Nel nostro sistema gli *heartbeat* periodici sono *time-driven* e usano un fanout adattivo $k = \log \text{Fanout}(n)$, dove $n = |\text{peers}|$. Ad ogni tick il nodo seleziona k vicini casuali (shuffle RNG locale) e invia: (i) HEARTBEATLIGHT con pochi *peer-hints* (finestra rotante di ampiezza hintMax), (ii)

HEARTBEATFULL con snapshot (servizi+peer). Lo *HB(full)* include la lista completa dei peer nel payload, ma è spedito solo a k destinatari (*one-hop*). La riconciliazione *push-pull* (anti-entropy/repair) è *time-driven* o on-demand quando il meta remoto è più nuovo. Su overlay ben connessi, la copertura avanza in $O(\log n)$ round; il costo per nodo degli HB cresce come $O(\log n)$ (via k).

B. Rumor mongering e regole di arresto

Il *rumor mongering* (o *rumor spreading*) diffonde eventi “caldi” (es. richieste di lookup, notifiche di stato) in modo probabilistico/limitato. Per evitare tempeste di messaggi si usano tre manopole:

- **TTL** (hop massimi): limita la profondità della propagazione;
 - **Fanout B** : numero di vicini contattati ad ogni hop;
 - **Budget F** : limite ai reinvii per *rumor ID* (dedup) o, in varianti equivalenti, una probabilità di continuazione p [2].
- Ogni nodo mantiene la memoria dei rumor visti con un contatore; superato F smette di inoltrare. Questo taglia la ridondanza rispetto al flooding mantenendo alta la probabilità che almeno un cammino raggiunga un provider. *Nota.* Nel seguito useremo “**rumor**” per le propagazioni event-driven (lookup, *Suspect/Dead/Leave*) e “**anti-entropy**” per la riconciliazione periodica push-pull. Per le proprietà di complessità e copertura rimandiamo alle formulazioni classiche [1], [2].

C. Anti-entropy (riparazione periodica)

L'anti-entropy è una riconciliazione periodica *time-driven* dello stato tra coppie casuali di nodi: ci si scambia un *digest* (riassunto compatto di versioni/epoch) e, solo se emergono divergenze, si trasferisce lo stato mancante via *push-pull*. A differenza del rumor (che è *event-driven*), l'anti-entropy garantisce *eventual consistency* [1], [3].

D. Bimodalità: rumor veloce + riconciliazione

Combinando rumor mongering (per gli eventi) e anti-entropy (per lo stato) si ottiene una diffusione *bimodale*: propagazione rapida e probabilistica quando serve reattività, con una riparazione periodica che chiude i buchi residui e abbassa la varianza. È il pattern adottato qui: heartbeat/light/full e (opzionale) repair periodico per allineare membership/servizi, rumor per lookup e segnalazioni di guasto.

E. Failure detection a heartbeat

In sistemi parzialmente sincroni, heartbeat periodici aggiornano la *liveness*; il mancato arrivo entro una soglia induce stato di *suspicion*, e il protrarsi oltre un secondo timeout porta allo stato *dead*. Parametri troppo aggressivi aumentano i falsi positivi; parametri conservativi rallentano la rimozione dei nodi guasti. Nel progetto si usa un FailureDetector a soglia temporale, con rumor epidemici *Suspect/Dead/Leave* che si propagano con le stesse manopole (B, F, TTL) del rumor; l'anti-entropy e gli heartbeat *full* contribuiscono a ripristinare/propagare la vista corretta [4]. Inoltre adottiamo un **quorum dinamico** per la promozione *Suspect*→*Dead*, calcolato come maggioranza di *peer vivi entro DEAD_TIMEOUT*.

III. DOCKER PER LA SPERIMENTAZIONE

Docker è una piattaforma di containerizzazione che permette agli sviluppatori di impacchettare applicazioni e tutte le loro dipendenze in unità standardizzate chiamate container. Questi container possono essere eseguiti in modo rapido, affidabile e coerente su qualsiasi macchina, sia locale che nel cloud, semplificando la creazione, il test e il rilascio del software e garantendo l'isolamento e l'indipendenza dell'applicazione dall'ambiente sottostante. Nel progetto lo usiamo per (i) descrivere la topologia in modo dichiarativo con `docker compose` (cfr. [6]), (ii) scalare localmente il numero di nodi per esplorare i parametri (B, F, TTL), e (iii) iniettare guasti controllati (stop/restore dei container) per misurare l'impatto su gossip e failure detection (cfr. [5]).

La topologia del progetto comprende: (i) un *registry* minimale usato solo per fornire un *peer* di bootstrap (TCP 9000), esplicitamente escluso dal *data path* dei lookup; (ii) N nodi gossip che comunicano su UDP (porte 9001–9006) e ospitano i provider; (iii) un *client* effimero che esegue il *lookup* (UDP 9009). Tutti i container condividono la stessa rete bridge di Compose e si risolvono per nome (*registry*, *node1*, ...). Parametri e *feature flags* (*heartbeat*, *repair*, *caching*) sono esternalizzati in `.env` per rendere gli esperimenti ripetibili; i file `compose` e il codice sono disponibili nell'artifact del progetto [7].

IV. PROGETTO SDCC: OBIETTIVI, FLUSSI E SCELTE

A. Obiettivi

Obiettivi: (i) service discovery decentralizzato dopo un bootstrap minimo; (ii) robustezza a churn/guasti;

B. Architettura e flussi (sintesi)

Il registry è solo *seed*. L'overlay e la vista emergono via gossip.

- **HB light (one-hop):** piggyback di *peer-hints* + metadati (*epoch*, *svcver*); aggiorna *lastSeen*.
- **HB full:** snapshot (*servizi+peer*) quando serve coerenza più forte (es. cambio servizi) e come risposta ai *repair*.
- **Lookup rumor:** il client diffonde (TTL, B, F); il primo provider risponde *direct-to-origin*. Negative cache temporanea sul miss.

- **Failure handling:** oltre *SUSPECT_TIMEOUT* si emette *Suspect*. La promozione a *Dead* avviene *solo* al raggiungimento del **quorum dinamico** $\lfloor (\text{alivePeerCount}() + 1)/2 \rfloor + 1$, dove *alivePeerCount* conta i *peer* con *HB* entro *DEAD_TIMEOUT* (*alive window*) escluso il nodo stesso. Si applicano *tombstone* e rumor *Dead*. *Leave* applica direttamente *Dead+tombstone*. Il *reval* è accettato solo con metadati più recenti della *tombstone*.
- **Repair (anti-entropy) opzionale:** scambio *push-pull* on-demand (o periodico a flag) basato su digest verso un sottoinsieme casuale di vicini vivi.

a) *Flussi in breve:* **Bootstrap:** seed dal registry, avvio HB light e ampliamento via piggyback. **Mutazioni servizi:** *ADD/DEL* → *bump* (*epoch/ver*) → HB full push. **Lookup:** *dedup* per *reqId*, risposta se provider vivo, forward a B vicini ($TTL-$), miss → *neg-cache*. **FD:** *Suspect* dopo *SUSPECT_TIMEOUT*, *Dead* per quorum; filtro di freschezza evita *Dead* se arriva un HB recente. **Repair:** HB full su richiesta o periodico se abilitato.

C. Feature flags e parametri runtime

a) Sintesi:

- **LearnFromHB:** se attivo, gli HB(*full*) ricevuti aggiornano *Service View* e *Peer View*; se disattivo, gli HB(*full*) sono ignorati (resta solo la *liveness* dagli HB(*light*)).
- **LearnFromLookup:** se attivo, il *client originator* apprende il mapping *service* → *provider* dalla prima *LookupResponse* e lo memorizza localmente.
- **RepairEnabled:** abilita l'*anti-entropy* periodica (*push-pull*); efficace solo con *LearnFromHB=true* (il ricevente deve accettare i *full*).

b) Interazioni pratiche:

- *RepairEnabled=true & LearnFromHB=true:* *repair efficace*, i tick *push-pull* periodici allineano le viste.
- *RepairEnabled=true & LearnFromHB=false:* *repair inefficace*, i *full* circolano ma il ricevente non apprende.
- *LearnFromLookup=true:* la prima risposta al *lookup* aggiorna la mappa locale *service*→*provider* del richiedente, riducendo la latenza dei lookup successivi.
- *LearnFromLookup=false & LearnFromHB=false:* nessun apprendimento passivo dei provider; la discovery dipende solo da risposte dirette o aggiornamenti espliciti.
- **Negative cache** (*SDCC_LOOKUP_NEGCACHE_TTL*): quando un rumor di lookup esaurisce il *TTL* senza trovare un provider, il nodo mette il servizio in *neg-cache* per un intervallo finito e lascia cadere richieste uguali fino a scadenza; la cache si invalida allo scadere del *TTL*.

c) Altri flag e timer (riassunto):

- **Rumor-mongering (FD):** *SDCC_FD_B* = fanout B ; *SDCC_FD_F* = budget F per rumor *ID*; *SDCC_FD_T* = *TTL* (hop).
- **Heartbeats:** *SDCC_HB_LIGHT EVERY* (periodo *light*); *SDCC_HB_FULL EVERY* (periodo *full*); *SDCC_HB_LIGHT_MAX_HINTS* (max *peer-hints* nei

lightriduce il payload degli HB(light) ma rallenta la diffusione dei peer via hint).

- **Failure detector (timeout):** SDCC_SUSPECT_TIMEOUT e SDCC_DEAD_TIMEOUT per le soglie *Suspect/Dead*.
- **Repair (anti-entropy):** SDCC_REPAIR_ENABLED abilita il push-pull periodico; SDCC_REPAIR_EVERY è l'intervallo.
- **Lookup:** SDCC_LOOKUP_TTL = profondità del rumor di lookup; SDCC_LOOKUP_NEGCACHE_TTL = durata della *negative cache*.
- **Osservabilità e client:** SDCC_CLUSTER_LOG_EVERY = periodo del log ">> Cluster ..."; SDCC_CLIENT_DEADLINE = deadline della modalità *client one-shot* per attendere la *LookupResponse*.
- **Registry bootstrap:** SDCC_REGISTRY_MAX_ATTEMPTS = tentativi massimi di bootstrap verso il registry.
- **RPC (servizi demo):** SDCC_RPC_A, SDCC_RPC_B controllano i parametri dei servizi aritmetici d'esempio.

V. AMBIENTE SPERIMENTALE IN DOCKER

A. Topologia e deployment

Usiamo docker compose per avviare una topologia minimale e ripetibile:

Tutti i container stanno sulla rete bridge di Compose (DNS interno: registry, node1, ...). L'aggiunta/rimozione di servizi avviene tramite file di controllo (ADD/DEL) e innesca un gossip *full*. Timer e flag sono in .env per consentire sweep controllati.

VI. PSEUDO-CODICE DEI FLUSSI CHIAVE

Algorithm 1 Lookup rumor (lato nodo)

```

[1]
on LOOKUP(reqId, svc, ttl, B, F, origin) from s
if dedup[reqId] ≥ F then return
end if
dedup[reqId] ← dedup[reqId] + 1
if knownProvider(svc) and isAlive(provider) then
    if dedup[reqId] == 1 then
        send LOOKUPRESPONSE(reqId, provider) to origin
    end if
    return ▷ rispondo e mi fermo (niente forward)
end if
if ttl == 0 then
    negativeCache.insert(svc, now + Δ) ▷ Δ =
    LOOKUP_NEGCACHE_TTL
    return
end if
ttl ← ttl - 1
E ← {s, origin, self} ▷ evita eco e ping-pong
N ← randomAliveNeighbors(B, exclude = E)
for all n ∈ N do
    forward LOOKUP(reqId, svc, ttl, B, F, origin) to n
end for

```

Algorithm 2 Heartbeat light/full e failure rumors (compatto)

```

[1]
every Tl: send HB_LIGHT(hints, meta) to randomFanout()
▷ ≈ log n
every Tf: send HB_FULL(services, peers, meta) to
randomFanout()
on HB from p: lastSeen[p] ← now
periodicamente:
    need ← ⌊  $\frac{\text{alivePeerCount}() + 1}{2}$  ⌋ + 1
for all p do
    if now - lastSeen[p] > SUSPECT_TIMEOUT and
state[p] = Alive then
        rumor(SUSPECT(p), B, F, TTL); quickProbe(p)
    end if
    if suspectVotes[p] ≥ need and not recentHB(p) then
        state[p] ← Dead; purgeProviders(p); tombstone(p)
        rumor(DEAD(p), B, F, TTL)
    end if
end for
on LEAVE from p:
    state[p] ← Dead; purgeProviders(p); tombstone(p); ru-
mor(DEAD(p), B, F, TTL)
on RUMOR(ev, p, ttl, B, F, id) from s:
if dedup[id] ≥ F or ttl < 0 then return
end if
dedup[id] ← dedup[id] + 1
if ev = SUSPECT and not recentHB(p) then addVote(p, s)
end if
if ev ∈ {DEAD, LEAVE} and not recentHB(p) then
    state[p] ← Dead; purgeProviders(p); tombstone(p)
end if
if ttl > 0 then
    ttl ← ttl - 1; forward RUMOR(ev, p, ttl, B, F, id) to B
    random neighbors \ {s, p, self}
end if

```

VII. DISCUSSIONE CRITICA

Riassumiamo i principali trade-off progettuali con rischi e contromisure operative.

- **Negative cache.** *Pro*: contiene tempeste su miss ripetuti. *Contro*: rischio *starvation* se un servizio nasce subito dopo il miss.
- **Failure detector (HB one-hop).** *Pro*: semplice e prevedibile. *Contro*: falsi positivi sotto jitter/loss; sensibilità a skew. *Mitigazione*: timeouts proporzionali a HB(light); quorum per promuovere Dead.
- **Rumor per eventi (B, F, TTL).** *Pro*: copertura rapida con costo per nodo quasi costante. *Contro*: copertura insufficiente su overlay sparsi o traffico eccessivo. *Mitigazione*: tuning per profilo di rete [1].
- **Anti-entropy (repair) push-pull.** *Pro*: chiude buchi informativi; garantisce convergenza eventuale. *Contro*: overhead periodico in quiete. *Mitigazione*: $T_{\text{repair}} \gg T_{\text{HB(full)}}$.
- **Servizi owner-only.** *Pro*: implementazione semplice; coerenza locale forte; misure più pulite. *Contro*: disponibilità

più bassa; latenza più variabile; interazione più delicata con la negative cache..

- **Schema bimodale (gossip + repair).** *Pro:* reattività agli eventi + riconciliazione periodica; robustezza a loss/churn. *Contro:* tuning delicato di intervalli e parametri.
- **Quorum per Suspect → Dead.** *Pro:* riduce falsi positivi e rumor isolati. *Contro:* rilevazione più lenta; rischio di stallo in partizioni piccole.

VIII. MINACCE ALLA VALIDITÀ

Sicurezza (minacce & mitigazioni):

- **DoS/DDoS sul control-plane:** flood di join/ping/ping-req e gossip che saturano CPU/banda. **Mitigazione:** rate limiting per peer, circuit-breaker, code prioritarie, verifiche firma prima di lavori costosi, fanout e payload massimi.
- **Amplificazione/Reflection (UDP):** il nodo risponde più di quanto riceve. **Mitigazione:** cookie di ammissione/challenge-response, no risposte ad indirizzi non verificati.
- **Spoofing:** identità/nodo falsi o molte identità per inquinare il cluster. **Mitigazione:** NodeID = hash della chiave pubblica, mTLS/PKI (SPIFFE/SPIRE), join token/whitelist.
- **MITM:** intercettazione e modifica dei messaggi. **Mitigazione:** canale autenticato e cifrato.
- **Replay/Downgrade:** reinvio di record vecchi o versioni inferiori. **Mitigazione:** versioni monotone (Lamport/contatore), TTL brevi, nonce/anti-replay cache; i tombstone prevalgono.

IX. CAMPAGNA SPERIMENTALE

A. Setup e metodologia

Gli esperimenti sono stati eseguiti usando la Topologia introdotta nella sezione V Ambiente Sperimentale in Docker. La distribuzione dei servizi nei log di riferimento è:

- node1: sum node3: div node4: mul node2, node5: sub.

I parametri, caricati da .env, salvo diversa indicazione, sono:

- Rumor-mongering FD: $B=3$, $F=2$, $T=3$; HB light/full: 3s/9s.
- Timeouts FD: Suspect= 30s, Dead= 36s.
- Lookup: TTL= 3, LEARN_FROM_LOOKUP ∈ {true}, LEARN_FROM_HB ∈ {true}.
- Repair anti-entropy: REPAIR_ENABLED ∈ {false}, periodo 30s.

B. Casi sperimentali

Abbiamo variato alcuni flag e alcune configurazioni dei nodi:

a) *E1 — Baseline (HB-learn + Lookup-learn, no repair):*

I client eseguono lookup con TTL=3, $B=3$, $F=2$. Osservazioni:

- **Latenza:** risposta rapida; nei log di esempio la LookupResponse arriva nella stessa seconda della TX Lookup.
- **Cache locale:** il client aggiorna la mappa (“registry updated: svc → provider”) e invoca l’RPC.

- **HB light/full:** propagano metadati e snapshot servizi; aggiunte/rimozioni forzano full immediato.

b) *E2 — Disabilitare l’apprendimento da HB (learnFromHB=false):* Ogni nodo non chiede il HB(full) quando riceve HB(light) sospetti/obsoleti; nei log si vede: “[REPAIR] skip: learnHB=false → non richiedo HB(full) a ...”.

- **Effetto:** la convergenza della service view dipende dai rumor di lookup e dalle risposte (se learnFromLookup=true).
- **Discovery:** il lookup continua a funzionare (il provider risponde direttamente al client), ma l’allineamento passivo via HB è ridotto.

c) *E3 – Crash (fail-stop): Azione:* docker kill -s SIGKILL nodeX. *Atteso:* entro SUSPECT_TIMEOUT rumor Suspect, quindi Dead per quorum. Durante la tombstone, rumor/HB obsoleti sono ignorati.

d) *E4 – Leave volontario: Azione:* docker stop nodeY (il processo invia Leave). *Atteso:* applicazione immediata di Dead+tombstone senza fase Suspect; propagazione rumor con (B, F, TTL).

e) *E5 – Rientro: Azione:* riavvio di nodeX con metadati (epoch/ver) maggiori della tombstone. *Atteso:* HB(full) accettato, transizione da guardia a Alive; in caso contrario HB scartati fino a bump dell’incarnation.

f) *E6 – Join a caldo: Con registry:* nodo richiede un seed (registry:9000) e avvia HB/light; vista converge in pochi cicli. *Senza registry:* bootstrap diretto su un vicino vivo (--bootstrap-peer=node2:9002); semantica identica, niente SPOF sul path dei lookup.

X. CONCLUSIONI E LAVORI FUTURI

Abbiamo descritto un service discovery decentralizzato in Go che unisce rumor mongering, anti-entropy e failure detection a heartbeat con orchestrazione Docker. **Lavori futuri:**

- Difesa contro DoS/DDoS, spoofing, MITM, replay.
- Auto-tuning di gossip/FD guidato da misure online di RTT e perdita.
- Scalabilità/robustezza: stress test a n elevato.

REFERENCES

- [1] A. Demers et al., “Epidemic algorithms for replicated database maintenance,” 1988.
- [2] R. Karp et al., “Randomized rumor spreading,” 2000.
- [3] W. Vogels, “Eventually Consistent,” 2009.
- [4] N. Hayashibara et al., “The ϕ -Accrual Failure Detector,” 2004.
- [5] Docker Inc., “Docker Engine Overview,” <https://docs.docker.com/engine/>.
- [6] Docker Inc., “Compose file reference (Compose Specification),” <https://docs.docker.com/compose/compose-file/>.
- [7] L. Polidori, “SDCC_Gossiping (artifact e sorgenti),” <https://github.com/Polidori1999/ProgettoSDCC>.